

生成 AI を用いた事前シミュレーション支援

2025/09/09 島岡敦哉

前回の議論

- 複数資料と会話情報からどのような結果が出るのかを調査してみる
- 過去や前回での指摘されたことを踏まえたプロンプトにしていく

会話情報の取り扱いについて

会話情報を入力とするが、累積していくと大量のトークンが必要になる。

よって、3つの対策を考えている

1.要約型

議論の文字起こしを学習者自身で要約し、重要な指摘や改善点だけを抽出

- ・学習者の 振り返り効果・メタ認知が高まるが、要約の 質にばらつきが出る可能性

2.メタデータ抽出

議論会話から自動で「指摘点」「改善要求」などを抽出し、簡単な箇条書きで保存

メリット

- ・検索性が高く、過去の指摘を簡単に参照可能
- ・構造化データとして管理できるため、分析や自動質問生成に適している

デメリット

- ・自動抽出の精度に依存

3.検索可能なナレッジベース化

過去の議論ログ全文を分割・ベクトル化し、資料に関連する部分だけを検索して活用。

メリット

- ・過去の情報を ほぼ損失なく利用可能
- ・大量の議論履歴でも 必要な部分だけ抽出できる

デメリット

- ・検索結果を GPT に送る際に トークン消費が発生

プロンプト設計と出力

過去の議論と資料、それに対する自分の説明と議論を受けて、これらを補完した今の資料への質問生成を受ける。

1. 今回議論で扱うべき問い生成

過去との差分や指摘の反映状況を踏まえ、今回の議論で扱うべき問いを2個生成してください。

問いは必ず「過去との差分」や「過去の指摘の反映状況」に触れること。

===== 出力 1 =====

1. 今回のプロンプト設計は「過去の議論・前回の指摘」からどの具体的差分を取り込んでいますか？ 取り込んだ差分は RAG や会話情報の扱い（要約型／メタデータ抽出／ナレッジベース化）のどの方法で反映され、各方法について期待される効果と主要なリスク（例：トークン消費、抽出精度のばらつき、学習者の内省促進とのトレードオフ）をどう定量・定性で評価しますか？（次回までに示せる検証指標・テストケースを挙げてください）

意図：過去→現在の差分反映の透明性と、それを支えるアーキテクチャ選択の妥当性を突く。

1. 「資料作成支援／議論振り返り支援」における改善項目（例：差分可視化、マインドマップ→資料反映支援、**出力・修正過程のデータベース化**）の中で優先実装すべきものは何ですか？ その優先順位を過去の指摘との比較で根拠づけ、優先実装後に期待する学習者の行動変容（内省の深さ、議論準備度、指摘反映率等）を具体的指標で示してください。また、実装後に短期的に行う評価プロトコル（実験条件・評価尺度）をどう設計しますか？

意図：実務的な実装優先度の妥当性確認と、成果を示すための評価計画を要求する。

2. 議論シミュレーション用の問い生成

今回の資料を読んだ参加者が議論前に疑問に思いそうな点を生成してください。

問いは「内容の正しさ」に加えて「研究の進展（過去からの改善や新課題）」に触れること。

===== 出力 2 =====

1. 会話情報の扱い（要約 / メタデータ抽出 / 全文 RAG）について、どの方式が「過去指摘の喚起力・質問品質・学習者の内省促進」と「トークン負荷・自動化耐性」を最も良く両立するかを、どの評価軸・実験条件で比較・決定しますか？
 - なぜ有効か（意図）：次回で方式を議論・決定するために、具体的な比較基準と「どの証拠を持ってくるべきか」を明確にする。
2. 「**過去との差分**」を踏まえつつ、かつメタ的・批判的な問い（意図や設計選択を問う質問）を高確度で生成させるためのプロンプト／パイプライン設計はどうする

か？（例：差分抽出→差分の因果推論→問いタイプ別生成（事実確認／方法批判／次段階提案）を明示した段階化）

- なぜ有効か（意図）：RAG はファクト系に強い一方でメタ的問いが弱い点を補い、会議で深い議論を誘導する質問を安定的に作るため。

3. 差分分析を意識した問い生成

過去の資料・指摘・議論内容と今回の資料を比較し、以下を生成してください。

- 前回から改善された点
- 依然残る課題
- 上記に基づく議論で扱うべき問い

問いは具体的かつ実践的に。

===== 出力 3 =====

1. 「『過去の議論／指摘の差分』を LLM にどう明示するか」で具体例を示してください。

目的：本研究の強みは差分を活かす点なので、抽象論で終わらず、実運用で再現可能なフォーマット（例：〈過去指摘〉→〈今回の修正〉→〈未解決点〉のテンプレ）と、それを用いたプロンプト→出力の生データ（少なくとも 2 例）を見たいです。

準備してほしいもの：

- 差分表現のフォーマット（テンプレ）と採用理由（なぜその粒度／順序か）
- そのフォーマットを埋めた具体的な入力例（過去指摘の原文、今回資料の抜粋、あなたの短い応答）
- その入力で生成された「壁打ち用質問」の出力例（LLM の返答）と、評価ルーブリック（妥当性・独創性・実践可能性の各尺度での採点基準）

2. 会話情報の取扱（要約型／メタデータ抽出／全文 RAG）について、トークン消費・生成質問の質・実装コストを定量的に比較する実験計画を提示してください。

目的：各方式の実用上のトレードオフと、どの条件でどれを採用すべきかを判断可能にするため。特に「RAG は事実性に強いがメタ的・批判的問いが弱い」という指摘への対策（ハイブリッド設計）が重要です。

準備してほしいもの：

- 比較実験の設計：データセット（過去議論のサンプル数）、各方式での前処理手順、評価指標（例：質問の再現率、想定議題へのカバー率、メタ問いの割合、トークン量）
- 期待する閾値／成功基準（例：メタ問い率が xx% 以上、トークン量削減率が yy% 以上）

- 実装上の留意点と暫定的な解決策（自動抽出誤りへの対処、Forest/XMLとの連携方針、RAG+CoT やポストフィルタでメタ問いを補完する案）

4. 学習者進歩の確認用問い生成

過去指摘と今回の資料を基に、学習者がどの点で成長したか、どの点が未対応かを評価する問いを3個作成してください。

問いは「過去→現在→次への橋渡し」を意識して設計。

===== 出力 4 =====

1. 会話情報の取り扱い（要約型・メタデータ抽出・ナレッジベース化）のどの方式、あるいは組合せを採用するかを決める際、過去の議論ログから「指摘の頻度」「指摘の重要度」「指摘の再発性」をどのように定量化して比較し、トークン消費・自動抽出精度・学習者のメタ認知効果というトレードオフを定量的に評価する最小実験設計（必要データ量・評価指標・比較条件）を具体的に示せますか？

意図・準備ポイント：過去ログを用いた指摘抽出のサンプル集計・簡易評価指標案（F1, 再現率, 人間評価スコア等）と、各方式を比較するためのスプリット案を用意する。

1. 「過去の差分から新しい問いを生成する」という本研究の強みを維持しつつ、RAG が苦手とするメタ的・批判的問いの生成をどう担保しますか？具体的には、
 - (a) プロンプトで差分や会話コンテキストをどのように構造化して提示するか、
 - (b) 生成された問いの質（新規性・批判度・実務性）を評価する定量／定性指標と、その評価結果をシステム（データベース）にどうフィードバックして次回生成に反映させるかを示してください。

意図・準備ポイント：差分表現のテンプレート（例：前回指摘・反映有無・現資料の対応箇所）と、問い評価の評価表（尺度例）＋フィードバックフロー図を用意する。

今後の方針

- ・会話情報をさらに取り入れて、サンプル数を増やし、実験していく
- ・プロンプトとして何が良いか、選択し、学習者がリフレクションできるデザインを深掘りする